

# 融合多特征的水声通信信号调制识别方法\*

王 洋<sup>1,3,4,5</sup> 沈同圣<sup>2</sup> 汪 涛<sup>2†</sup> 乔 钢<sup>1,3,4,5</sup> 周 锋<sup>1,3,4,5</sup> 刘 峰<sup>2</sup>

(1) 哈尔滨工程大学 水声技术全国重点实验室 哈尔滨 150001)

(2) 军事科学院国防科技创新研究院 北京 100071)

(3) 哈尔滨工程大学 水声工程学院 哈尔滨 150001)

(4) 哈尔滨工程大学三亚南海创新发展基地 三亚 572024)

(5) 工业和信息化部 海洋信息获取与安全工信部重点实验室(哈尔滨工程大学) 哈尔滨 150001)

2023年10月16日收到

2023年12月11日定稿

**摘要** 针对水声通信信号的特征易受信道噪声和多径效应等复杂水声环境的影响导致识别率较低的问题,提出了一种融合多特征的水声通信调制识别方法。首先,为获取抗噪性能更强的信号特征,设计了小波时频特征与平方功率谱、自相关谱的最强两谱线特征相融合的方法;其次,基于迁移学习理论构建轻量化网络模型,以时频特征完成2FSK和4FSK信号的识别;最后,设计粒子群优化的支持向量机,根据最强两谱线特征实现对非频移键控信号(包括BPSK、QPSK、DSSS和OFDM信号)的识别。仿真结果表明该方法对水声信道和环境噪声具有良好的泛化能力,海试数据验证了该方法的识别率优于现有的神经网络模型。

**关键词** 水声通信, 调制识别, 多特征融合, 轻量化网络

PACS: 43.60, 43.30

DOI: [10.12395/0371-0025.2023246](https://doi.org/10.12395/0371-0025.2023246)

CSTR: [32049.14.11-2065.2023246](https://doi.org/10.12395/0371-0025.2023246)

## Modulation classification method based on multi-feature fusion for underwater acoustic communication signals

WANG Yang<sup>1,3,4,5</sup> SHEN Tongsheng<sup>2</sup> WANG Tao<sup>2†</sup> QIAO Gang<sup>1,3,4,5</sup> ZHOU Feng<sup>1,3,4,5</sup> LIU Feng<sup>2</sup>

(1) National Key Laboratory of Underwater Acoustic Technology, Harbin Engineering University Harbin 150001)

(2) National Innovation Institute of Defense Technology, Academy of Military Sciences Beijing 100071)

(3) College of Underwater Acoustic Engineering, Harbin Engineering University Harbin 150001)

(4) Sanya Nanhai Innovation and Development Base of Harbin Engineering University Sanya 572024)

(5) Key Laboratory of Marine Information Acquisition and Security (Harbin Engineering University),

Ministry of Industry and Information Technology Harbin 150001)

Received Oct. 16, 2023

Revised Dec. 11, 2023

**Abstract** Feature extraction of communication signal is easily affected by complex underwater acoustic interferences such as high noise and multipath effect, which lead to low classification rate. To solve this problem, a modulation classification method based on multi-feature fusion for underwater acoustic communication signals is proposed. First, the multi-feature fusion method is designed to obtain signal features with stronger noise immunity, including wavelet time-frequency spectrum and two stronger spectral line features from square power spectrum and autocorrelation spectrum. Secondly, based on transfer learning theory, a lightweight network model is constructed to classify 2FSK and 4FSK signals using time-frequency features. Finally, combined with support vector machine optimized by particle swarm algorithm, an interclass recognition for non-frequency shift keying signals (including BPSK, QPSK, DSSS, OFDM signals) is designed using two stronger spectral line features. The results of simulation experiments demonstrate that the proposed method has good generalization abilities and noise immunity against underwater acoustic channels.

The sea trial data verifies that the proposed method outperforms common neural network models in the classification rate.

**Keywords** Underwater acoustic communication, Modulation classification, Multi-feature fusion, Lightweight network

## 引言

水声通信信号调制识别技术在水下通信领域发挥着重要的作用。常用的水声通信信号调制识别方法主要包括基于似然比以及基于特征提取的识别方法, 基于似然比的识别方法<sup>[1]</sup>依赖于接收信号时假设的先验知识, 其适用性场景少。而基于特征提取的识别方法具有较低的计算复杂度, 应用于水声通信领域, 包括瞬时特征<sup>[2]</sup>、星座图特征<sup>[3]</sup>、能量统计特征<sup>[4]</sup>、周期平稳特征<sup>[5,6]</sup>、高阶累积量特征<sup>[7,8]</sup>、短时傅里叶变换特征<sup>[9]</sup>、光谱特征<sup>[10]</sup>和波形直方图特征<sup>[11]</sup>等。文献[12-14]利用时频特征构建识别网络, 以实现信号的识别, 但单一特征受环境影响较大, 导致其在实际应用中整体识别率较低。

为了获得更有效、稳定的特征, 多域特征融合为水声通信信号识别提供了新的思路。赵自璐等<sup>[15]</sup>利用支持向量机(SVM)提取信号的 Stockwell 变换域能量熵特征、循环谱、幅值统计特征等, 提高了识别准确率, 但 SVM 参数未进行优化, 对训练样本识别速度较慢。Miao 等<sup>[16]</sup>利用时频特征, 引入了前向特征融合, 消除了特征图上的网格化伪影, 实现水声通信信号的识别, 但其需要进一步考虑水声环境噪声的影响。Gao 等<sup>[17]</sup>通过监督对比学习损失函数集中同一类别的特征向量, 这种方法针对多进制相移键控(MPSK)和多进制频移键控(MFSK)两类信号进行识别。对于正交频分复用(OFDM)信号, 方涛等<sup>[18]</sup>基于信道盲均衡提取了信道衰落系数, 实现了 OFDM 类内调制识别。

近年来, 神经网络技术广泛应用于信号特征的自动提取, 完成水声通信信号调制识别任务, 如卷积神经网络<sup>[19,20]</sup>、混合时间序列网络<sup>[21]</sup>、基于分数低阶压缩变换的残差网络<sup>[22]</sup>。姜楠等<sup>[23]</sup>构建稀疏自动编码网络, 从接收信号的谱信息中自动提取有效谱特征, 提升了模型的识别性能。进一步地, Li 等<sup>[24]</sup>利用信号的时频特征训练网络, 实现调制识别, 该网络中具有自适应软阈值的多头自注意力模块, 以此抑制噪声的影响, 然而其对训练数据的需求较大。Wang 等<sup>[25]</sup>提出一种脉冲噪声预处理、注意力网络和少样本学习的架构, 可以有效地提取特征, 但其对二进制相移键控(BPSK)和正交相移键控(QPSK)的实测数据识别率较低。Zhang 等<sup>[26]</sup>将递归神经网络和卷积神经

网络相结合, 无需人工提取特征即可获得更高的识别精度, 但在构建识别网络模型时需注意计算资源消耗问题。

针对水下环境噪声和多径效应的影响导致水声通信信号识别率低的问题, 本文提出一种融合多特征的水声通信信号调制识别方法。首先, 引入小波时频特征和平方功率谱、自相关谱的最强两谱线特征的融合方法, 获得更明显的特征, 为神经网络展示更多的信号信息。其次, 结合迁移学习策略, 将水声通信信号的时频特征输入轻量化网络模型识别, 显著降低了整个模型的计算复杂度, 提升了识别效率。此外, 设计粒子群优化的支持向量机模型, 得到最优参数, 根据最强两谱线特征实现了信号调制识别率的提高。最后, 通过仿真和浅海试验验证了所提方法能够降低环境噪声和多径效应影响, 相对其他传统网络, 识别率更高, 泛化能力较强。

## 1 水声信道模型

考虑到水声信道中存在多径效应和环境噪声等诸多复杂因素, 本文将水声信道构建为多尺度多滞后(MSML)信道, 信道模型省略了由地理位置和声速的不确定性引起的大尺度衰落参数<sup>[27,28]</sup>, 则接收信号  $S_{\text{sig}}(t)$  应表示为

$$S_{\text{sig}}(t) = Y(t) + n(t) = \sum_{l=1}^L \theta_l(t)y_l(t) + n(t), \quad (1)$$

其中,  $\theta_l(t)$  为第  $l$  个路径的复数衰减,  $n(t)$  为高斯白噪声,  $y_l(t)$  为经过水声信道的延迟、相移和频移的发送信号:

$$y_l(t) = x(t - \tau_l - \phi_l(t))e^{-j2\pi f_o(\tau_l + \phi_l(t))}, \quad (2)$$

其中,  $\tau_l$  为第  $l$  路径的初始到达时间,  $f_o$  为载波频率,  $x(t)$  为发送的通信信号, 包括二进制频移键控(2FSK)、四进制频移键控(4FSK)、二进制相移键控(BPSK)、正交相移键控(QPSK)、直接序列扩频(DSSS)和正交频分复用(OFDM)信号, 表示为

$$x(t) = \sum_{m \in \mathbb{Z}} b_m g(t - mT_s), \quad (3)$$

其中,  $b_m$  为发送的符号,  $g(\cdot)$  为脉冲整形滤波器,  $T_s$  为假设接收机已知的符号持续时间,  $\phi_l(t)$  为由多普勒缩放产生的函数:

$$\phi_l(t) = \frac{v_l}{c}t + \frac{a_l}{2c}t^2, \quad (4)$$

其中,  $c$  为声速,  $v_l$  为发射机和接收机之间的相对速度,  $a_l$  为相对加速度。

## 2 融合多特征的水声通信调制识别方法

本文所提方法的整体流程如图 1 所示, 主要包括验证多特征提取方法、构建轻量化网络和设计粒子群优化的支持向量机等部分。首先, 输入水声通信信号, 利用连续小波变换获得时频特征, 基于迁移学习策略构建轻量化卷积神经网络模型 (TL-SqueezeNet), 将信号分为 2FSK、4FSK 和非频移键控信号; 其次, 提取信号平方功率谱的最强两谱线幅值, 利用粒子群优化的支持向量机 (PSO-SVM), 将非频移键控信号分为 [BPSK, DSSS] 和 [QPSK, OFDM]; 最后, 提取信号自相关谱的最强两谱线特征, 结合 PSO-SVM 方法实现 [BPSK, DSSS] 和 [QPSK, OFDM] 信号的类间识别。

### 2.1 多特征提取方法

为了提取更明显的多域信号特征, 本文融合了小波时频特征和最强两谱线特征, 以提高信号特征的抗噪能力。

#### 2.1.1 小波时频特征

在水声通信过程中, 由于发送信号为调制信号,

其频率、幅度和相位参数在不同发码元之间产生变化。小波变换利用可伸缩平移的特性去除了水声通信信号的突变部分, 集中了时频点能量, 以此反映了信号的时频特征<sup>[29]</sup>。2FSK 和 4FSK 信号的载波频率随基带信号在频率点间变化, 在时频图上与非频移键控信号存在差异, 因此, 利用连续小波变换提取水声信号的时频特征, 将信号分为 2FSK、4FSK 和非频移键控信号。信号的连续小波变换为

$$W(a, \beta) = \int S_{\text{sig}}(t)\mu(t)dt = \frac{1}{\sqrt{a}} \int S_{\text{sig}}(t)\mu_a^*\left(\frac{t-\beta}{a}\right)dt, \quad (5)$$

其中,  $a$  为伸缩因子,  $\beta$  为平移因子,  $\mu(t)$  为母小波函数, 其满足以下前提条件:

$$Z_{\mu(t)} = \int \frac{|\mu(\omega)|^2}{|\omega|} d\omega < \infty, \quad (6)$$

其中,  $\mu(\omega)$  为  $\mu(t)$  的傅里叶变换。

#### 2.1.2 平方功率谱和自相关谱的最强两谱线特征

平方功率谱能反映平方信号的功率分布特性, 自相关谱可以描述信号在两个不同时刻状态的内在联系, 但是在水声通信中, 非频移键控信号的平方功率谱和自相关谱特征变化不明显, 不适合直接输入到网络模型中。为了识别非频移键控信号, 本文提出了最强两谱线特征提取方法。

信号的功率谱可以由 Welch 法得到, 当信号序列划分为  $K$  段时, Welch 法将相邻分段重叠以提高方差性能, 并利用窗函数提高谱估计的分辨率。第  $k$  段

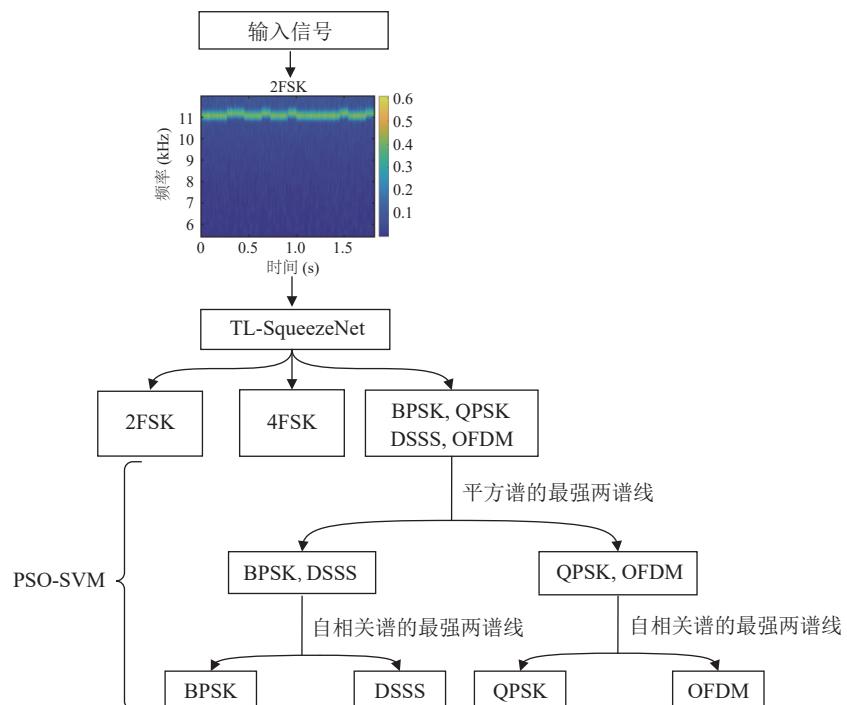


图 1 整体流程图

信号的功率谱表示为

$$P_{\text{PSD}}^k(\omega) = \frac{1}{UM} \left| \sum_{i=0}^{M-1} S_{\text{sig}_M^k}(i) w(i) e^{-j\omega T} \right|^2, 1 \leq k \leq K, K \leq \frac{N}{M}, \quad (7)$$

其中,  $M$  为第  $k$  段信号的长度,  $N$  为信号的长度,  $w(i)$  为窗函数,  $U$  为归一化因子:

$$U = \frac{1}{M} \sum_{i=0}^{M-1} w^2(i). \quad (8)$$

则 Welch 功率谱为

$$P_{\text{PSD}}(\omega) = \frac{1}{K} \sum_{k=1}^K P_{\text{PSD}}^k(\omega). \quad (9)$$

进一步可以得到平方功率谱为

$$P(\omega) = P_{\text{PSD}} \left\{ S_{\text{sig}}^2(t) \right\}. \quad (10)$$

以相移键控信号 (PSK) 为例,  $S_{\text{sig}}^2(t)$  可以表示为

$$S_{\text{sig}}^2(t) = \left[ \sum_{m=-\infty}^{\infty} g(t-mT_s) A_m e^{j\theta_m} \right]^2, \quad (11)$$

其中,  $A_m$  为常数,  $\theta_m = 2\pi(m-1)/\gamma$ ,  $\gamma$  为 2 的整数次幂。BPSK 信号载波相位存在  $\pi$  变, 对其进行平方变换后,  $e^{j2\theta_m} = 1$ , 其平方功率谱在二倍载频处出现离散单频分量<sup>[30]</sup>。同理, DSSS 信号的平方功率谱在二倍载频处存在离散分量, QPSK 和 OFDM 信号则无此特征。

信号  $S_{\text{sig}}(t)$  的自相关谱由自相关函数进行傅里叶变换得到, 其自相关函数为

$$R_{S_{\text{sig}}, S_{\text{sig}}}(\Delta t) = E[S_{\text{sig}}(t_1) S_{\text{sig}}(t_2)] = E[S_{\text{sig}}(t_1) S_{\text{sig}}(t_1 + \Delta t)], \quad (12)$$

$$S_{\text{sig}}(t_1) S_{\text{sig}}(t_1 + \Delta t) = [Y(t_1) + n(t_1)][Y(t_1 + \Delta t) + n(t_1 + \Delta t)], \quad (13)$$

其中,  $t_1, t_2$  为时间,  $\Delta t$  为时间间隔, 则式 (12) 可转化为以下形式:

$$R_{S_{\text{sig}}, S_{\text{sig}}}(\Delta t) = \int S_{\text{sig}}(t_1) S_{\text{sig}}(t_2) dt = R_Y(\Delta t) + R_{Yn}(\Delta t) + R_{nY}(\Delta t) + R_n(\Delta t), \quad (14)$$

其中,  $R_Y(\Delta t), R_n(\Delta t)$  为信号和噪声的自相关项,  $R_{Yn}(\Delta t), R_{nY}(\Delta t)$  为信号和噪声的互相关项。由于水声信道中噪声与信号无关, 互相关项为零, 即  $R_{Yn}(\Delta t) = R_{nY}(\Delta t) = 0$ , 则自相关函数可化简为

$$R_{S_{\text{sig}}, S_{\text{sig}}}(\Delta t) = R_Y(\Delta t) + R_n(\Delta t). \quad (15)$$

结合以上设计提取最强两谱线特征。对信号的平方功率谱和自相关谱归一化后, 搜索谱图的最大值作为第一谱线。进而将以第一谱线为中心的附近谱图置零, 置零范围约为通信带宽的 1/10, 选取此时谱图的最大值作为第二条谱线, 以此获得非频移键控信号的调制识别依据。

### 2.1.3 多特征融合方法可行性分析

分析小波时频特征、平方功率谱和自相关谱的最强两谱线特征, 论证多特征融合方法对于 6 种水声通信信号识别的可行性。

#### 2.1.3.1 小波时频特征

基于 2.1.1 节的分析, 图 2 给出了信噪比为 6 dB 的水声通信信号的时频特征。结果表明, 2FSK 信号有 2 个频率点, 4FSK 信号有 4 个频率点, 频移键控信号的特征均存在频率偏移。而非频移键控信号的时频特征相似, 且没有频率偏移, 表明连续小波变换提

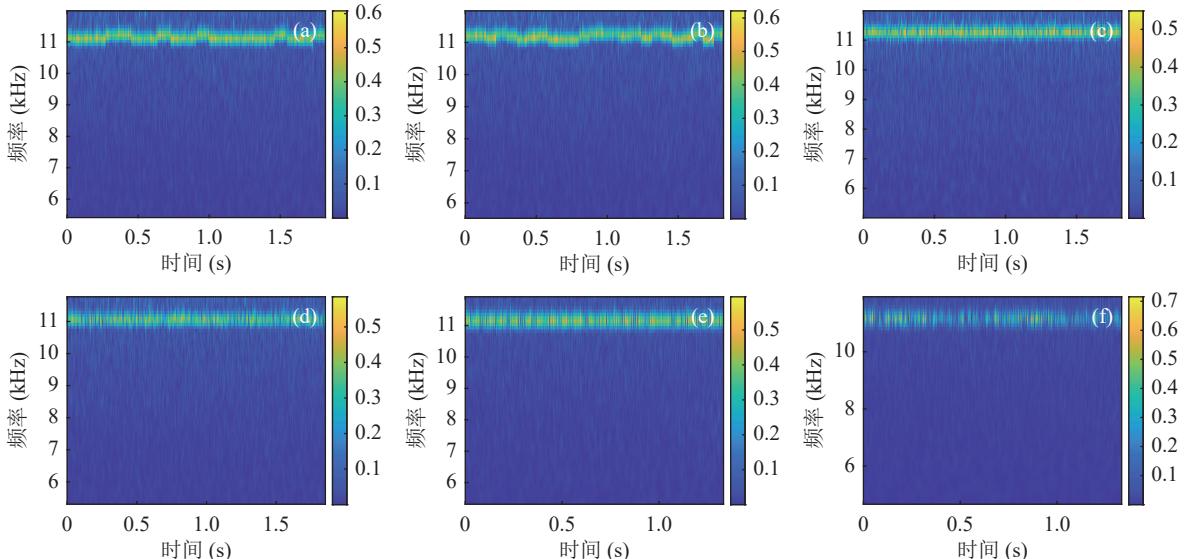


图 2 小波时频图 (a) 2FSK; (b) 4FSK; (c) BPSK; (d) QPSK; (e) DSSS; (f) OFDM

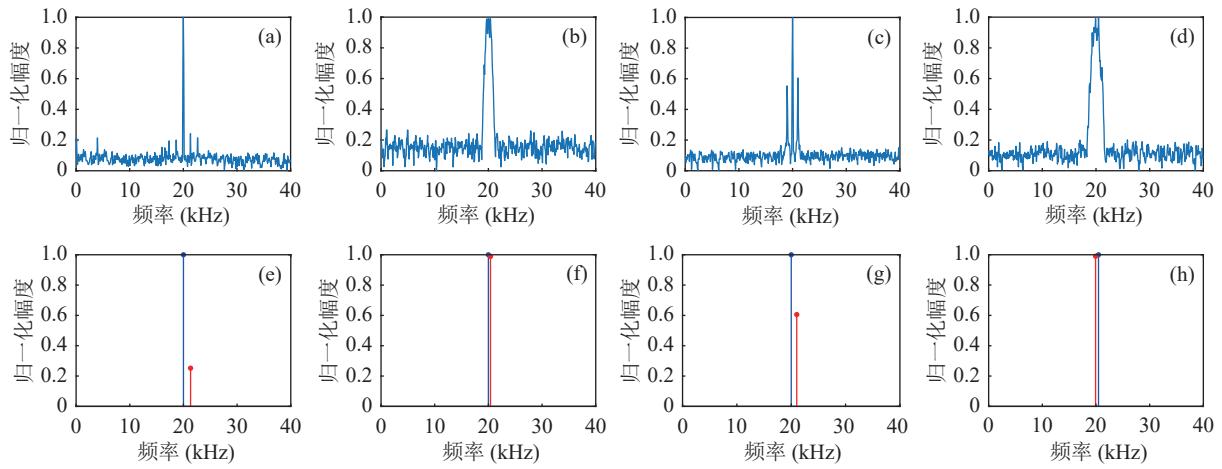


图3 平方功率谱的最强两谱线特征 (a) 平方功率谱, BPSK; (b) 平方功率谱, QPSK; (c) 平方功率谱, DSSS; (d) 平方功率谱, OFDM; (e) 最强两谱线, BPSK; (f) 最强两谱线, QPSK; (g) 最强两谱线, DSSS; (h) 最强两谱线, OFDM

取的时频特征可有效实现 2FSK、4FSK 和非频移键控信号的识别。

#### 2.1.3.2 平方功率谱的最强两谱线特征

针对非频移键控信号的识别,在信噪比为 6 dB 时,提取平方功率谱的最强两谱线特征,如图 3 所示。当载频为 10 kHz 时,BPSK 和 DSSS 信号的平方功率谱在二倍载频处出现离散分量,QPSK 和 OFDM 信号则无此特征。同时,BPSK 信号的第二谱线幅值为 0.2,DSSS 信号为 0.6,而 QPSK 和 OFDM 信号大于 0.9。考虑信号特征的抗噪性,在信噪比-6~16 dB 下进行 200 次特征提取,其统计结果如图 4 所示。在信噪比大于-2 dB 时 BPSK 信号的第二谱线在 0.25 左右,DSSS 信号在 0.6 左右,而 QPSK 和 OFDM 信号大于 0.9。图 3 和图 4 表明,利用平方功率谱的最强两谱线特征可以将非频移键控信号分为两类:1) BPSK 和 DSSS;2) QPSK 和 OFDM。

#### 2.1.3.3 自相关谱的最强两谱线特征

在非频移键控信号被分为:1) BPSK 和 DSSS;2) QPSK 和 OFDM 后,进一步以自相关谱实现类间识别,达到四种信号调制识别的目的。

基于 2.1.2 节最强两谱线特征在识别 BPSK 和 DSSS 信号中的分析,在信噪比为 6 dB 时,提取 BPSK 和 DSSS 信号的特征,如图 5 所示。由于 DSSS 信号结构中包含 PN 码,其自相关谱会出现多个峰值,而 BPSK 信号有且仅有一个峰值。图 6 为信噪比-6~16 dB 下 200 次特征分布。在信噪比大于-2 dB 时,DSSS 信号的第二谱线大于 0.1,在信噪比等于 16 dB 时约为 0.25,而 BPSK 信号均小于 0.1,证明该方法针对水声通信中 BPSK 和 DSSS 信号的分类具有可行性。

同理,图 7 分析了最强两谱线在识别 QPSK 和

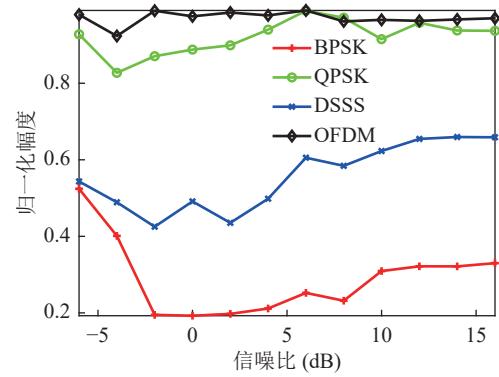


图4 平方功率谱的第二谱线幅值

OFDM 信号方面的可行性。OFDM 信号由于循环前缀的存在,自相关谱出现两个峰值,第二谱线约为 0.2,而 QPSK 信号仅有 1 个峰值,且接似于 0。信噪比-6~16 dB 下 200 次特征的统计结果如图 8 所示。当信噪比  $\geq -2$  dB 时 OFDM 信号的特征大于 0.2,当信噪比等于 16 dB 时接近 0.45,而 QPSK 信号均小于 0.05。因此该特征可以识别水声通信中的 QPSK 和 OFDM 信号。

综上分析,采用小波变换时频图和最强两谱线特征的多特征融合方法能够清晰地表征 6 种水声通信信号特点,实现信号的调制识别。

## 2.2 轻量化网络

考虑到现有水声通信信号调制识别网络模型,计算过程需要耗费大量计算资源和内存,本文基于迁移学习策略构建轻量化卷积神经网络模型 (TL-SqueezeNet),通过减少结构参数提高性能。

SqueezeNet 将卷积神经网络的卷积层拆分为两部分 (Squeeze 层和 Expand 层),进而封装到 Fire 模块,如图 9 所示。Squeeze 层由  $1 \times 1$  的卷积核构成,

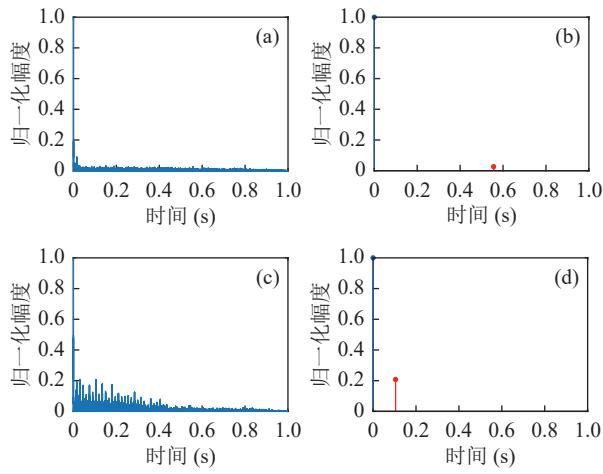


图 5 自相关谱及其最强两谱线特征 (a) 自相关谱, BPSK; (b) 最强两谱线, BPSK; (c) 自相关谱, DSSS; (d) 最强两谱线, DSSS

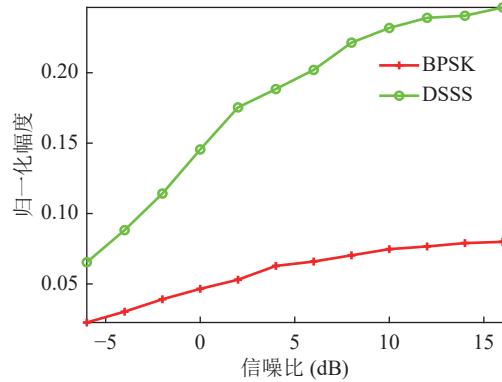


图 6 自相关谱的第二谱线幅值

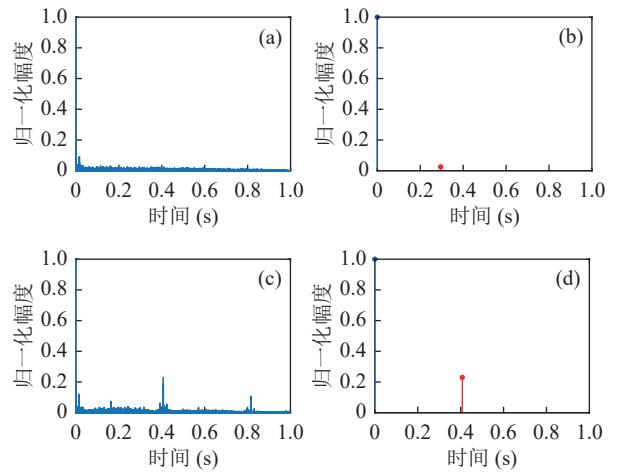


图 7 自相关谱及其最强两谱线特征 (a) 自相关谱, QPSK; (b) 最强两谱线, QPSK; (c) 自相关谱, OFDM; (d) 最强两谱线, OFDM

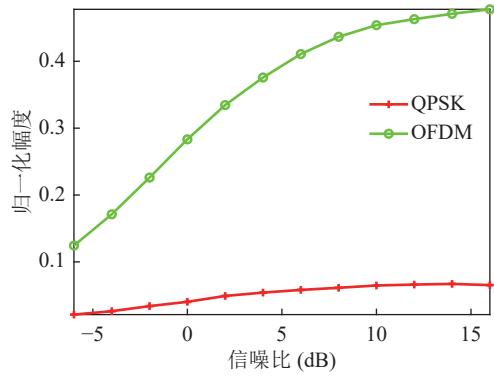


图 8 自相关谱的第二谱线幅值

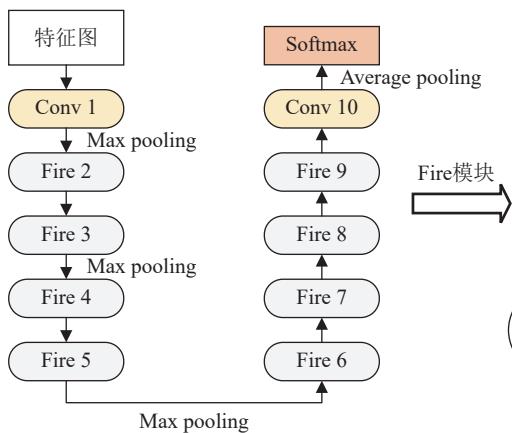


图 9 SqueezeNet 网络架构

数量为  $S_{\text{Squeeze}}$ 。特征图经该层后通道数变少, 大小不变, 以此增强了网络的非线性表达能力。Expand 层由  $E_1$  个  $1 \times 1$  和  $E_2$  个  $3 \times 3$  两种卷积核构成, 满足  $S_{\text{Squeeze}} < E_1 + E_2$ 。在忽略偏置的情况下, 一个 Expand 层的参数量  $Y_{\text{Squeeze}}$  为

$$Y_{\text{Squeeze}} = \text{Con} \times \text{Num} \times 3 \times 3, \quad (16)$$

其中, Con 为卷积核数量, Num 为输入通道数。由

式 (16) 可知, Expand 层将网络的参数量降低了 9 倍。

### 2.3 粒子群优化的支持向量机

为提高非频移键控信号的分类精度, 本文结合粒子群算法优化 SVM 的惩罚系数 Pen 和参数 Ker。SVM 目的是找到一个满足分类标准的最优超平面, 超平面可表示为

$$f(x) = \sigma^T + \varepsilon, \quad (17)$$

其中,  $\sigma$  为法向量, 决定平面方向,  $\varepsilon$  为偏置量。面两侧点到平面的距离为

$$r = \frac{|\sigma^T + \varepsilon|}{\|\sigma\|}. \quad (18)$$

距离  $r$  最大值等价于求解  $\min_{\sigma, \varepsilon} \|\sigma\|^2 / 2$ 。由于水声信号的数据集是线性不可分的, 需根据 PSO 理论优化 Pen 和 Ker, 其中 Pen 表征对误差的宽容度, Ker 将低维样本映射到高维空间。PSO 首先初始化可行解中的一组粒子, 每个粒子都有自身的速度、位置和适应值, 在每一次迭代中粒子通过个体最优值和全局最优值更新自己, 最终得到粒子最优解, 实现 SVM 识别精度的提高, 算法过程如图 10 所示。

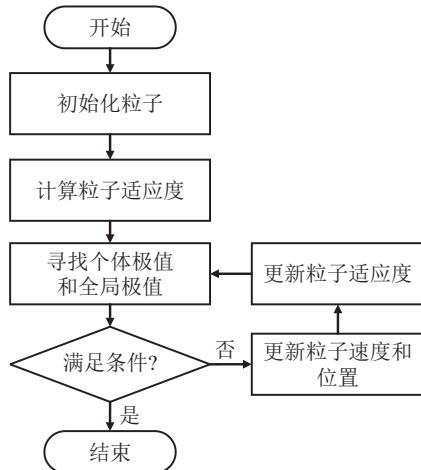


图 10 粒子群算法

### 3 实验与分析

针对仿真数据分析 TL-SqueezeNet + PSO-SVM 方法的泛化性、有效性和抗噪性, 以及多特征融合方法的识别性能, 并进一步利用浅海试验数据验证该

方法的有效性。

#### 3.1 数据集

基于第 1 节描述的统计模型, 使用水声信道模拟器实现时变信道。根据浅海试验数据参数设置两种不同的传输条件, 其参数如表 1 所示。海试地点为中国南海, 发射机和接收机布放深度约为 1 m, 收发距离约为 10 m。图 11 中计算并标记了  $h_1$  和  $h_2$  信道的路径延迟, 包括直达路径 (D)、表面反射 (S)、底部反射 (B) 以及底部表面 (B-S) 和表面–底部 (S-B) 反射。可以看出这些信道具有广泛的多径结构, 近似于同时到达,  $h_2$  信道中因各种反射引起的延迟高于  $h_1$  信道。由于实验信道包含不同的多径结构, 信号参数不相似, 且数据集之间存在差异, 因此研究识别网络的泛化能力十分必要。

表 1 数据参数

参数	Data_h1	Data_h2	浅海试验
发射机深度 (m)	5	10	1
接收机深度 (m)	10	12	1
传输距离 (m)	500	1000	10
采样频率 (kHz)	80	100	128
载波频率 (kHz)	[9, 12, 14]	[11, 13, 15]	[14, 20]
平方根升余弦滤波器滚降系数	0.5	0.5	—
符号速率 (Baud)	[1000, 2000]	[800, 1500]	2000
信噪比 (dB)	−6~16		21~23

#### 3.2 仿真结果与分析

##### 3.2.1 泛化性分析

为了评估不同水声信道条件下网络的泛化能力, Data\_h1 和 Data\_h2 进行交替训练和测试, 识别性能如图 12 所示。当经 Data\_h1 数据集训练的 TL-SqueezeNet + PSO-SVM 对 Data\_h2 数据集进行分类

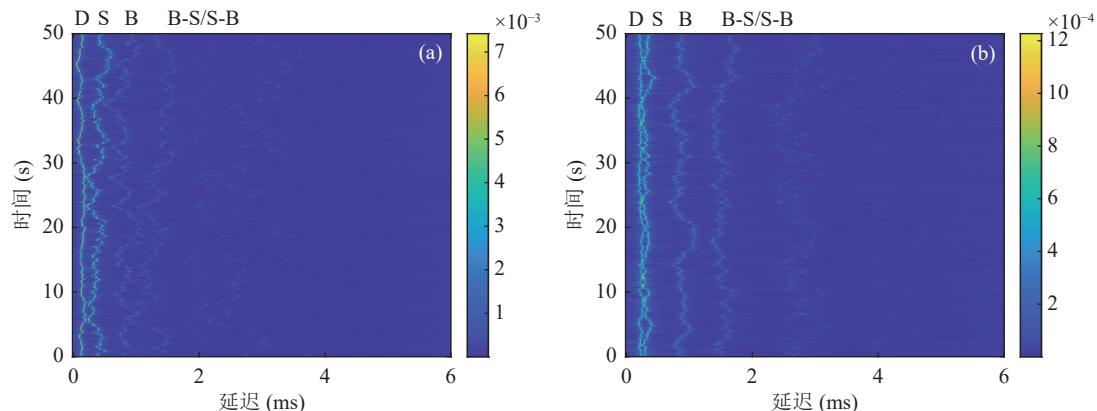


图 11 信道路径随时间的时延 (a)  $h_1$  信道; (b)  $h_2$  信道

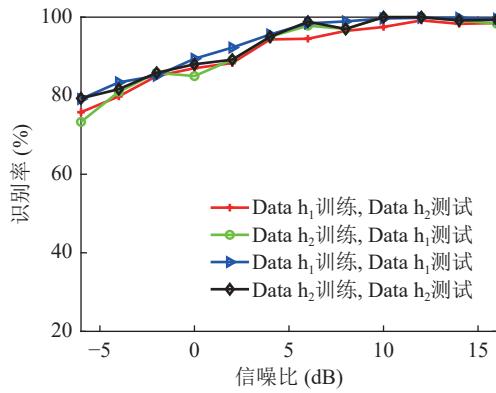


图 12 不同测试数据的识别率

时, 总体准确率持续上升, 信噪比大于 6 dB 时均接近 98%。在交换数据集识别后, 其分类性能相似, 证明在不同的测试数据下该网络均具有良好的泛化能力。

### 3.2.2 多特征融合方法性能分析

分析多特征融合方法的性能。分别利用不同特征对 Data\_h1 数据进行识别, 其中 80% 的数据为训练集, 10% 为验证集, 其余为测试集(本文中有效性和抗噪性分析的数据分配方式与此相同)。单一时频特征的识别网络为 TL-SqueezeNet, 时频特征与功率谱或自相关谱融合方法采用的网络为 TL-SqueezeNet + SVM, 结果如图 13 所示。在不同信噪比下, 多特征融合的识别率均高于其他特征融合和单一时频特征的识别, 体现了多特征融合方法具有良好的识别性能。

### 3.2.3 有效性分析

本实验探究 PSO-SVM 和轻量化网络在识别水声通信信号方面的有效性, 针对 Data\_h1 数据中 6 种水声通信信号, 在信噪比为 4 dB 时, 将其性能与不同网络进行对比, 如表 2 所示。结果表明, PSO-SVM 方法的整体调制识别率优于 SVM 方法和遗传算法优化的 SVM 方法(GA-SVM); SqueezeNet 的识别率高于 Alex 网络(AlexNet)、谷歌网络(GoogleNet)和残

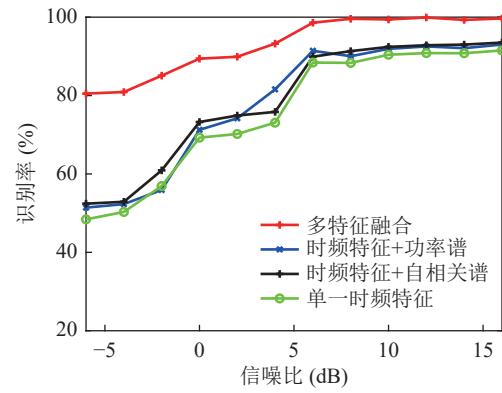


图 13 不同特征融合的识别率

表 2 不同模型的识别率

模型	特征	Data_h1
SVM	最强两谱线	79.11%
GA-SVM		83.17%
PSO-SVM		85.64%
TL-AlexNet	时频图	84.50%
TL-GoogleNet		82.93%
TL-ResNet		81.28%
TL-SqueezeNet		86.05%
TL-SqueezeNet + PSO-SVM	多特征融合	92.96%

差网络(ResNet); 本文所提网络 TL-SqueezeNet + PSO-SVM 的整体调制识别率最高, 达到 92.96%。

不同优化算法过程中每一代种群的适应度迭代曲线如图 14 所示。在 GA 寻优早期, 最佳适应度处于波动状态随后上升, 在 25 代达到 GA-SVM 分类模型的最优值, 为 87%; PSO 寻优早期最佳适应度保持上升趋势, 10 代以后种群可保持在最优, 达 92% 并趋于平稳, 计算效率较高。实验表明, PSO 算法具有更高的最优适应度, 且收敛速度更快, 优于 GA 算法。

此外, 基于训练时间、参数量、模型大小及单张图片处理时间对 4 种模型的算法复杂度进行对比, 结果如表 3 所示。SqueezeNet 的训练时间最短、效率高; SqueezeNet 的参数量和模型大小相较于 AlexNet

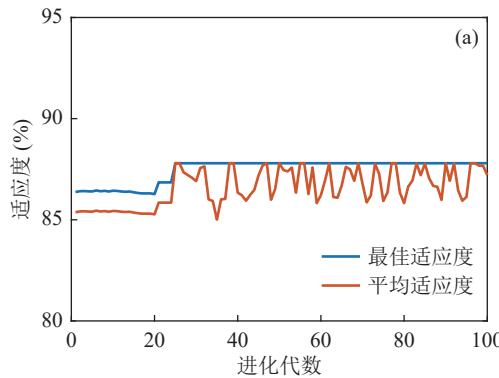
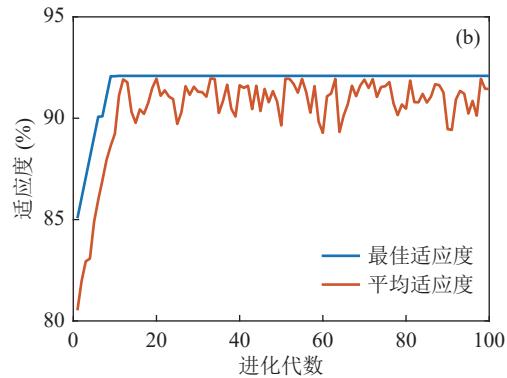


图 14 适应度曲线 (a) GA 算法; (b) PSO 算法



减少近 50 倍, 比 ResNet 减少 10 倍, 在实际应用中更便于模型部署; SqueezeNet 处理单张图片仅需 164 ms, 同一时间可处理更多的数据。这表明, 本文构建的网络具备轻量化特性和较高的有效性。

### 3.2.4 抗噪性分析

针对 Data\_h<sub>1</sub>, 6 种信号在不同信噪比下的识别率如图 15 所示, 每种调制信号的识别率随信噪比的增加而增加。当信噪比大于 6 dB 时, 所有信号均大于 98.5%, 验证了本文方法具有良好的抗噪性。

## 3.3 浅海试验验证

为进一步验证所提方法的有效性, 在南海海域进行了实际测试, 采集到的水声信号参数如表 1 所示。考虑浅海试验数据与仿真数据的采样率差异, 为适应经基于 Data\_h<sub>1</sub> 数据迁移训练的网络, 在测试

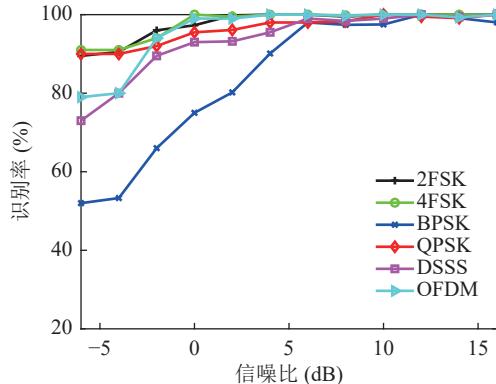


图 15 不同信号的识别率

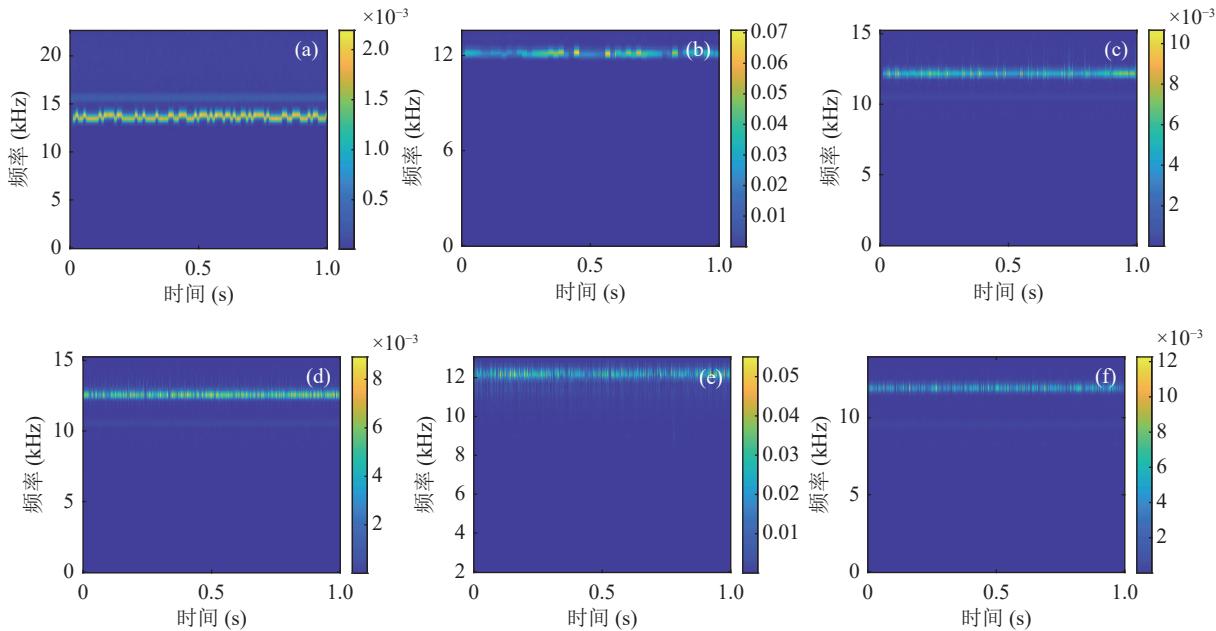


图 16 小波时频图 (a) 2FSK; (b) 4FSK; (c) BPSK; (d) QPSK; (e) DSSS; (f) OFDM

前对接收信号进行重新采样, 以获得相同的采样率, 由此得到每种调制模式各 200 个信号的测试集, 且每个信号的持续时间为 1 s。图 16 和图 17 分别为时频特征、平方功率谱和自相关谱的最强两谱线特征的分布。结果表明, 2FSK 和 4FSK 信号的时频特征与其他四种信号有显著差异; 根据平方功率谱的最强两谱线特征, QPSK 和 OFDM 信号均大于 BPSK 和 DSSS; 通过自相关谱的最强两谱线特征可以看出, BPSK 和 QPSK 信号较小, DSSS 和 OFDM 信号较大, 实验表明, 本文提出的多特征融合方法适用于实际浅海环境下水声通信信号的调制识别。

探讨所提方法与 AlexNet、GoogleNet 和 ResNet 方法对测试信号的性能, 其识别混淆矩阵如图 18 所示, 处理时间见表 4。对 6 种信号, TL-SqueezeNet + PSO-SVM 方法的识别率均在 97% 以上, 且处理时间仅需 10 min。这证明了当训练数据有限且测试信号

表 3 不同网络模型的性能

模型	训练时间 (min)	参数数量 ( $10^4$ )	模型大小 (M)	单张图片处理时间 (ms)
SqueezeNet	46	122	4.6	164
AlexNet	85	6096	227	285
GoogleNet	70	694	144	250
ResNet	62	468	44	221

表 4 不同模型所需处理时间

模型	TL-SqueezeNet + PSO-SVM	AlexNet	GoogleNet	ResNet
处理时间 (min)	10	21	17	14

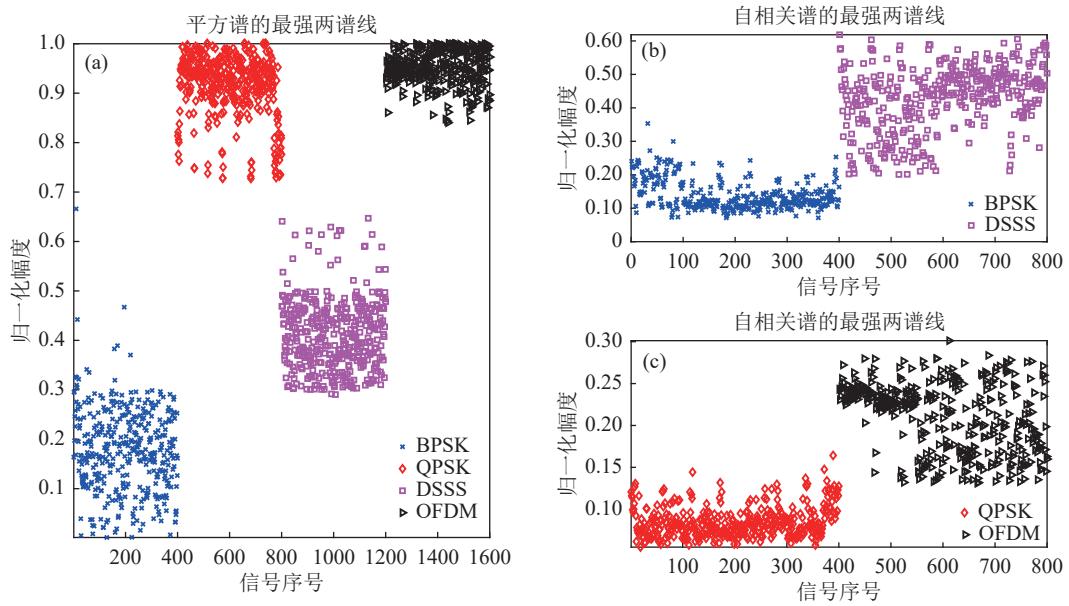


图 17 平方功率谱和自相关谱的最强两谱线特征 (a) 平方功率谱; (b) 自相关谱 (BPSK, DSSS); (c) 自相关谱 (QPSK, OFDM)

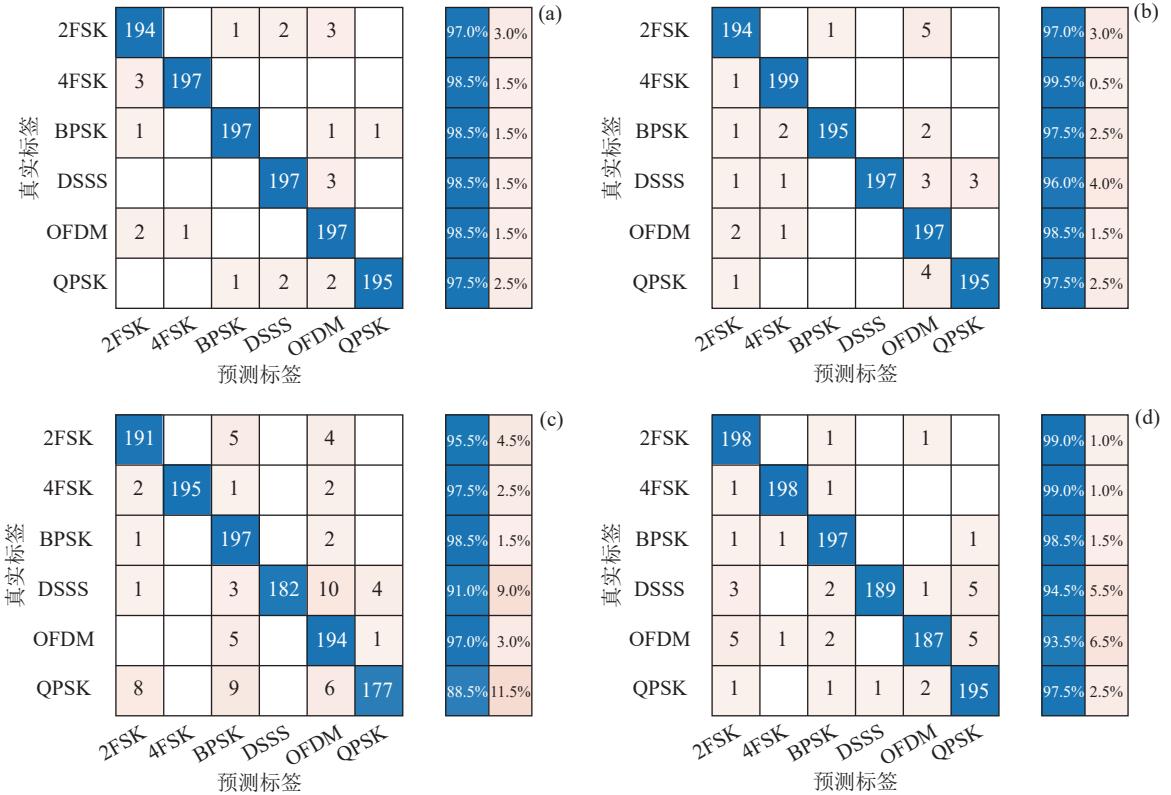


图 18 数据识别结果 (a) TL-SqueezeNet + PSO-SVM; (b) AlexNet; (c) GoogleNet; (d) ResNet

持续时间较短时, 本文所提方法采用的迁移学习策略可更好地适应测试通道对训练数据的需求, 实际水声信道下识别性能优于其他方法。

## 4 结论

本文针对水声 2FSK、4FSK、BPSK、QPSK、DSSS

和 OFDM 信号, 提出了基于迁移学习的轻量化网络和粒子群优化的支持向量机的多特征融合智能调制识别方法。分析了小波变换时频特征、平方功率谱和自相关谱的最强两谱线特征识别 6 种信号的可行性, 构建轻量化网络降低计算复杂度, 并设计粒子群优化的支持向量机进一步提高信号的识别准确度。仿真与海试结果表明, 所提方法可高效实现 6 种信

号的精确识别,有效减少多径效应和环境噪声的影响,同时降低内存需求,具有较好的泛化能力,识别性能优于传统算法。